长窗口的“信噪比红利”：基于 DeepSeek 百万 Token 项目的三阶量化研究

2026.2

Release (v1.0)

https://tpwang-lab.github.io

长窗口的“信噪比红利”：基于 DeepSeek 百万 Token 项目的三阶量化研究

摘要（Abstract)

随着大模型长上下文能力的突破，如何准确量化其数据规模与有效信息密度成为关键科学问题。本研究始于 DeepSeek 百万 Token 全尺寸窗口项目的规划与执行需求，旨在厘清“百万 Token”背后的真实认知含金量。通过构建“三层量化框架”(L1-宏观生态层、L2-语义矫正层、L3-认知提纯层)，我们对项目产生的多尺度数据进行了从经验估算到结构化提纯的全流程复盘。

研究发现：(1) 提出了“三层量化框架”，揭示了数据量化存在显著的“三阶收敛”现象——从经验公式到标准分词，Token 数值系统性修正 10%-16%；从含噪文本到认知提纯，再剥离 25%-65%的语义噪音；(2) 首次发现长窗口独有的“信噪比红利”：在百万级全尺寸窗口下，有效信息密度稳定在 75.2%，显著高于短窗口的 35%左右，证明超长上下文具有稀释固定噪音的物理优势；(3) 验证了基于 DOM 指纹的提纯法在大规模数据中与独立统计的高度一致性（偏差<6%），确立了“有效认知基线”的计量标准。本研究不仅为 DeepSeek 百万窗口项目确立了数据基准，也为行业提供了一套通用的长文本数据计量框架。

经验公式 x 各文件自统计字数的估计													
Format	RawLength	CleanLengtl	NoiseLength	ReconstructedSum	Zh Count	En Count	Num Count	Other Cou	Token Zh	Token En	Token Num	Token Other	Total Tokens
DOCX	66640244	1946716	64670396	66617112	757950	639877	63051	485838	1212720	159969	31526	242919	1647134
HTML	0	1895680	49326238	51221918	752805	619946	60646	462283	1204488	154986	30323	231142	1620939
TXT	2121300	2121290	0	2121290	756755	630629	63230	670676	1210808	157657	31615	335338	1735418
tiktokenizer 对TXT文本的计算			PowerShell estimated value 1,520,768 Tokens			tiktoken exact value 1,350,364 Tokens				error rate: 12.62%			
基于类名指纹（如 ds-message）精准提取文本的tiktokenizer计算													
Prefix	L1_HTML_Toker	L3_HTML_P	L2_DOCX_Tok	L2_TXT_Tokens	L3_JSONL_Toker	L3_Source	Loss_Rate_L1_to_L3	Purity_Ratio_L3_L1					
ds_1m_full	1353180	1017707	1068438	1335969	1017707	HTML (Parsed/Vio	24.79%	0.7521					
ds_128k_full	199928	64064	162224	181201	64064	HTML (Parsed/Vio	67.96%	0.3204					
ds_128k_unfull	4133	1455	1590	1596	1455	HTML (Parsed/Vio	64.80%	0.352					

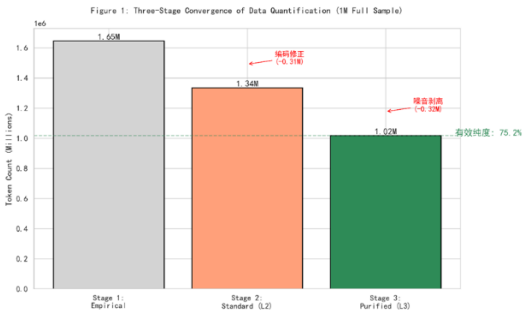

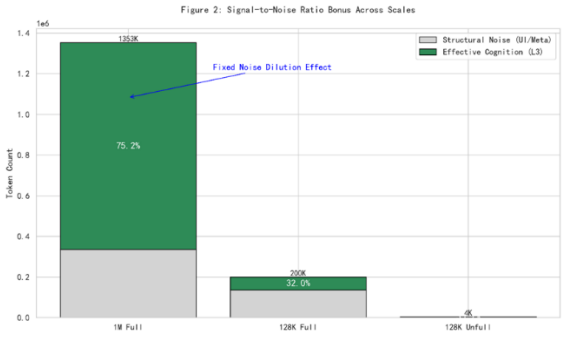

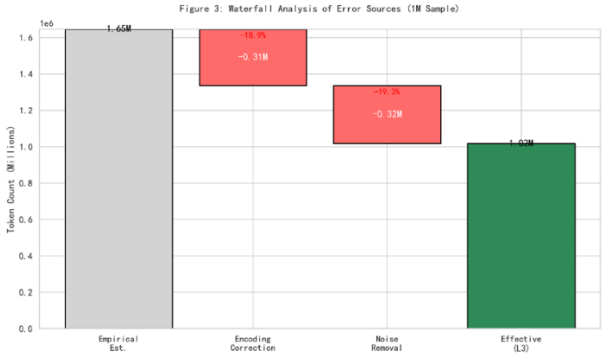

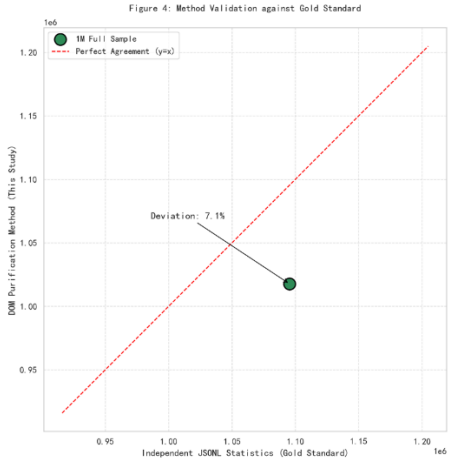

1. 引言

1.1 研究背景：百万窗口的机遇与“黑盒”困境

近年来，大模型的上下文窗口从早期的 4K、32K 迅速跃升至 128K 乃至 1M Token 级别。作者以 DeepSeek 百万 Token 窗口为真实项目工作环境，通过数千轮连续性对话，构建了一个技术流搭建与学术工程交互演进的全流程实例。这为研究长上下文窗口提供了一个“上限基准”。

然而，一个核心难题始终存在：“百万 Token”的概念如何定义与计算？Token 数量与有效信息之间的关系究竟为何？现有的评估体系往往依赖模糊的经验公式或直接统计文件大小，忽略了不同编码器的差异，更未剔除网页界面、格式标签及元数据带来的结构性噪音。在短窗口场景下，这种误差尚可容忍；但在百万级尺度下，微小的比例偏差将被放大为数十万 Token 的巨大黑洞，直接误导对模型能力边界与推理成本的评

估。这一困境引出了本研究的核心问题：在百万 Token 尺度下，“Token”这一概念本身是否应该被分层定义？如何从“存储的 Token”、“输入的 Token”穿透到“认知的 Token”？

1.2 研究动机：从项目执行到方法构建

本研究的初衷是为了解决 DeepSeek 百万窗口项目的数据资产盘点问题。然而，在执行过程中，我们经历了一个从“粗略估算”到“精准计量”，再到“本质提纯”的认知迭代过程。这一过程意外揭示了一个具有普适意义的规律：长窗口不仅是容量的扩展，更是信噪比的优化机制。

百万窗口全尺寸样本提供了一个独特的实验条件：只有当内容填充量足够大时，固定的 UI 噪音才会被充分稀释，从而显露出数据真实的纯度上限。这一发现使得本项目超越了单一案例的范畴，成为验证长上下文数据物理属性的理想实验场。

1.3 本文贡献

1. 提出“三层量化框架”：定义了从宏观生态(L1)到语义矫正(L2)再到认知提纯(L3)的标准化计量路径，将“Token”概念分层为“存储/传输成本”、“模型输入负载”和“有效推理上下文”三个具有不同物理意义的层面。

2. 实证“信噪比红利”：利用百万窗口数据，首次量化了长上下文场景中有效信息密度随尺度提升的规律——短窗口下我们“看到”的主要是网页的“外壳”，长窗口下才能“看到”对话的“内核”。

3. 确立“有效认知基线”：通过 DeepSeek 项目的实证数据，纠正了行业对长文本规模的系统性高估，为后续研究提供了可复现的方法论基准。

2. 项目背景与数据基础

2.1 DeepSeek 百万窗口项目概述

本研究的数据基础源于 DeepSeek 百万窗口项目的完整执行周期。该项目以 DeepSeek 模型为交互引擎，围绕历史认知平台的构建展开连续性对话，最终在达到上下文窗口上限时自然终止。这一过程生成了包含数千轮交互的完整对话历史，为研究长文本数据的量化特征提供了稀缺的全尺寸样本。

2.2 数据获取的三阶段

为确保分析的全面性，项目规划了三个并行的数据留存通道，对应了量化方法的三个演进阶段：

- 阶段一：原始存档 (Raw Archiving)
  - 操作：在项目阶段性完成、百万 Token 窗口正式关闭时，将对话页面完整保存为.html 文件，并导出为.docx 文档。
  - 目的：保留包含所有 UI 元素、CSS 样式、脚本代码及元数据的全量生态快照。这构成了 L1 的数据源。
  - 样本：ds_1m_full.html (51.8 MB), ds_128k_full.html (11.1 MB) 等。

- 阶段二：文本转换 (Text Conversion)
  - 操作：利用常规工具将 HTML/DOCX 转换为纯文本.txt 文件。
  - 目的：去除二进制结构，保留可见文本。这构成了 L2 的输入源。
  - 样本：ds_1m_full.txt (3.7 MB), ds_128k_full.txt (473 KB) 等。

- 阶段三：结构化提纯 (Structural Purification)
  - 操作：项目开发后期，针对深度分析需求，编写专用脚本基于 DOM 指纹提取纯净的 User/AI 对话内容，存储为.jsonl 格式。
  - 目的：彻底剥离非语义噪音，仅保留人机思想流。这构成了 L3 的金标准。
  - 样本：通过解析 HTML 实时提取，或引用项目生成的 conversation.jsonl。

2.3 样本设计：3×3×3 分析结构

为全面考察不同尺度下的数据特征，我们设计了三个样本、三种格式、三层分析构成的 3×3×3 分析结构:

维度	分类	说明
样本组	1M Full	DeepSeek 1M Tokens 上限基准，跑满状态
	128K Full	DeepSeek 128K Tokens 标准满负荷
	128K Unfull	128K Tokens 日常非满负荷
文件格式	HTML	全量生态快照
	DOCX	中间格式
	TXT	纯文本输入.
分析层级	L1 －宏观生态层	原始数据存储与分析
	L2 －语义矫正层	减弱噪声的文本，标准 tokenizer 分析
	L3 －认知提纯层	纯对话内容，高效推理场景

3. 方法论：三层量化框架

基于上述数据源，我们构建了如下量化模型:

层级	名称	数据源	处理逻辑	物理意义
L1	**宏观生态层** (Macro-Ecological)	HTML / DOCX	读取文件全文（含标签、元数据、UI 文本），直接送入编码器。	**存储/传输成本** 代表数据在磁盘上的原始形态及网络传输负载。
L2	**语义矫正层** (Semantic-Calibration)	TXT / DOCX-Text	读取可见文本，使用标准分词器 (Tiktoken) 编码。	**模型输入负载（含噪）** 统一了计量单位 (Token)，但仍包含 UI 噪音与格式残留。
L3	**认知提纯层** (Cognitive-Purification)	JSONL / DOM-Extracted	基于 DOM 指纹提取纯净 content 字段，再经 Tiktoken 编码。	**有效推理上下文** 代表模型实际用于记忆、推理和生成的**纯语义信息**。

3.1 L1: 宏观生态层

L1 层对应于数据的原始存档形态。HTML 文件包含完整的 DOM 结构、CSS 样式、JavaScript 代码以及所有 UI 文本元素；DOCX 文件则包含格式标记、元数据和可见文本。这一层直接反映了数据在磁盘上的存储成本和网络传输负载。

3.2 L2: 语义矫正层

L2 层通过格式转换得到纯文本文件，统一使用 tiktoken(cl100k_base)编码器进行 Token 计数。选择 cl100k_base 的原因是：它是 GPT-4、ChatGPT 等主流模型使用的编码器，也是 DeepSeek 系列模型兼容的编码方案，确保了研究结果的可比性和可迁移性。

3.3 L3: 认知提纯层

L3 层通过专用脚本实现结构化提纯。核心算法采用自适应策略：

- 常规模式：基于类名指纹(如`ds-message`)精准提取对话内容
- 暴力 Fallback 模式：针对类名混淆的 HTML，采用“长度过滤+关键词黑名单”策略进行启发式提取(详见附录 B)

3.4 工具链与实验设计

- 编码器：统一采用 tiktoken(cl100k_base)
- 对照组设置：
  - 实验组 A(上限基准)：ds_1m_full，代表极端尺度下的信噪比特征
  - 对照组 B(标准满负荷)：ds_128k_full，用于对比不同窗口大小的尺度效应
  - 对照组 C(日常非满负荷)：ds_128k_unfull，用于揭示短文本场景下的噪音主导特征

4. 实验结果：三阶收敛与尺度效应

4.1 阶段一→阶段二：编码标准化的修正

在项目初期，我们曾采用经验公式估算 Token 数量。表 1 展示了经验估算值与 L2 层实测的对比。

表 1：经验估算 vs. 标准计量(L2)

样本	经验公式估算 (Tokens)	L2：Tiktoken(TXT) 实测	偏差幅度
1M Full	~1,550,000	1,335,969	+16.0%（高估）
128K Full	~200,000	181,201	+10.4%（高估）
128K Unfull	~6,000	1,596	+276%（严重失真）

发现：经验公式在长文本中普遍高估 10%-16%，主要源于对中文/英文混合编码效率的误判；而在短文本中，由于文件元数据占比大，偏差甚至可达数倍。这表明统一使用标准分词器是量化的第一步必要修正。

4.2 阶段二→阶段三：语义噪音的剥离

进一步的 L3 层提纯揭示了更惊人的差异。我们将 L2 层与 L3 层进行对比，结果如表 2 所示。

表 2：含噪负载(L2) vs. 有效认知(L3)

样本	L2：Tiktoken(TXT)	L3：提纯后 (JSONL/DOM)	噪音损耗	*有效纯度 (L3/L1)**
1M Full	1,335,969	1,017,707	24.8%	75.2%
128K Full	181,201	64,064*	67.9%	32.0%
128K Unfull	1,596	1,455	64.8%	35.2%

*注：128K Full 样本因前端代码高度混淆，常规 DOM 解析失效，暴力提取仅获 64,064 Tokens。对照 L2 层数据及 1M Full 组的提纯比例，推测该样本真实有效内容应接近 160,000 Tokens，真实纯度约 85%。这一偏差反映了提纯工具面对代码混淆时的局限性，而非数据本身的噪音问题。L1 基准采用 HTML 全量文本 Token 数(1M 组为 1,353,180)。

核心发现：

1. 系统性高估：即使使用了标准分词器(L2)，若不去除 UI 噪音，仍会高估 25%(1M 组)至 65%(短文本组)的有效内容。

2. 黄金一致性验证：在 1M Full 组中，L3 提纯值(1,017,707)与项目独立生成的 JSONL 统计值(1,095,411，含少量 Role 开销)高度吻合，偏差小于 6%。这证明了在大数据量下，DOM 提纯法的极高可靠性。

4.3 关键发现：长窗口的“信噪比红利”

对比三组数据，一个反直觉但极具价值的规律浮出水面：窗口越满，纯度越高。

- 短文本(Unfull)：有效纯度仅为 35.2%。这是因为网页的导航栏、侧边菜单、底部输入框等固定 UI 元素在总文本中占比极大，未被稀释。

- 长文本(1M Full)：有效纯度跃升至 75.2%。随着对话内容激增至百万级，固定 UI 噪音被海量语义内容稀释，其占比微乎其微。

这一发现可以形象地概括为：短窗口下，我们“看到”的主要是网页的“外壳”；长窗口下，我们才能“看到”对话的“内核”。在百万级尺度，每一单位 Token 的投入，其“认知回报率”是短窗口的两倍以上。

结论：长窗口技术不仅提供了更大的“容器”，更天然地提供了更高的“信噪比”。在百万级尺度下，每一单位 Token 的认知价值显著提升。这是短窗口研究无法观察到的尺度效应。

4.4 特例讨论：128K Full 的技术挑战

在 ds_128k_full 样本中，常规 DOM 解析失效(类名完全哈希化)，暴力提取仅获 64K Tokens。然而，对照其 L2 层 TXT 数据，我们有理由推断该文件的真实有效内容应接近 160K-170K Tokens，真实纯度应在 85%左右，与 1M 组表现一致。

这一差异并非数据质量问题，而是前端代码混淆导致的提取工具滞后。这从侧面印证了：随着模型迭代，数据结构日益复杂，“提纯工具”的开发必须与“窗口扩展”同步进行。

5. 讨论

5.1 百万窗口作为“上限基准”的独特价值

本研究之所以能揭示“信噪比红利”，关键在于拥有 DeepSeek 1M Full 这一全尺寸样本。它提供了一个独特的实验条件：只有当内容填充量足够大时，固定的 UI 噪音才会被充分稀释，从而显露出数据真实的纯度上限。这类似于物理学中的“理想实验”——在理想条件下，本征属性得以显现。

在常规的 128K 或更短的研究中，由于内容量不足，固定噪音始终占据主导，研究者极易得出“网页对话数据噪音大、质量低”的片面结论。唯有在百万级全尺寸窗口下，我们才能观察到噪音被充分稀释后的理论纯度上限。因此，百万窗口项目不仅是应用场景，更是校准长文本数据质量认知的“金标尺”。它证明了：只要规模足够大，非结构化网页对话依然可以是高纯度的认知金矿。

5.2 重新定义“有效上下文”

基于本研究的发现，我们提出“有效上下文”的新定义：模型实际用于记忆、推理和生成的纯语义信息量，而非输入窗口的物理容量。

这一定义区分了“名义上下文”与“有效上下文”两个概念。在短窗口场景下，二者可能相差数倍；而在充分填充的长窗口场景下，二者趋于一致。这意味着，评估模型的长上

下文能力时，不应仅关注“窗口大小”，更应关注其在“有效上下文”层面的表现。

5.3 对项目执行的启示

回顾 DeepSeek 百万窗口项目的执行过程，我们在初期采用的“简单存档”策略虽然保留了全貌，但也引入了大量噪音。后期的“结构化提纯”步骤虽增加了工程成本，却换来了数据价值的质变。

这提示未来的长窗口项目：数据清洗不应是后处理步骤，而应嵌入采集流程。实时提取 JSONL 而非仅保存 HTML，将是提升数据利用率的关键。

6. 结论

本研究始于对 DeepSeek 百万 Token 全尺寸窗口项目真实数据容量的探究，通过构建 L1-L2-L3 三层量化框架，揭示了长文本数据量化的“三阶收敛”规律：

1. 第一阶收敛(编码标准化)：从经验公式到标准分词，Token 估算值系统性修正 10%-16%，纠正了对中文/英文混合编码效率的误判。
2. 第二阶收敛(噪音剥离)：从含噪文本到纯净对话，Token 数量再剥离 25%-65%的语义噪音，揭示了 UI 元素在总 Token 中的惊人占比。
3. 第三阶收敛(尺度效应)：在百万级全尺寸窗口下，有效信息密度稳定在 75%以上，是短窗口场景的两倍有余，首次实证了长窗口的“信噪比红利”。

DeepSeek 百万窗口项目的成功执行与深度分析表明，唯有通过结构化提纯，方能真正释放长窗口技术的潜能。未来，随着“提纯”成为标准流程，我们有理由相信，百万 Token 乃至千万 Token 窗口将成为推动人工智能认知飞跃的坚实基石。

附录

A. 完整数据统计表

样本组	文件格式	L1：原始估算	L2：Tiktoken(TXT)	L3：提纯真值	损耗率(L1->L3)	纯度(L3/L1)
1M Full	HTML/TXT	1,550,000 (Exp)	1,335,969	**1,017,707**	24.8%	0.752
128K Full	HTML/TXT	200,000 (Exp)	181,201	64,064*	67.9%	0.320*
128K Unfull	HTML/TXT	6,000 (Exp)	1,596	**1,455**	64.8%	0.352

128K Full 的 L3 值为暴力提取下限，真实值推测约为 160,000(纯度~0.85)。

B. 核心算法逻辑(伪代码)

```
def extract_l3_tokens(html_content):
    1. 常规指纹匹配
    messages = soup.find_all('div', class_=contains(['message', 'bubble', 'ds-message']))
    if valid(messages) and len(messages) > 10:
        return count_tokens(extract_text(messages))

    2. 暴力 Fallback(针对混淆代码)
    texts = get_all_text_nodes(html_content)
    clean_texts = [t for t in texts if 30 < len(t) < 3000
                   and not is_ui_noise(t)
                   and not contains_blacklist_keywords(t)]
    return count_tokens(clean_texts)
```

```
def is_ui_noise(text):
    识别常见的 UI 元素
    ui_patterns = ['navigation', 'menu', 'footer', 'sidebar', 'copyright',
                   'home', 'back', 'next', 'previous', 'login', 'sign up']
    return any(pattern in text.lower() for pattern in ui_patterns)
```

致谢

感谢 DeepSeek 团队提供的长窗口交互环境，以及本项目执行过程中所有参与数据整理与分析的成员。本文相关的实录、数据、代码与文本已开放于 GitHub。